

ENEM INSIGHTS

Relatório Técnico do Projeto de Portfólio

Rodrigo Torres | Ciência da Computação | Data Science

github.com/Rodrigotorres1/ENEM-Insights

1. Visão Geral

O ENEM Insights é um projeto de Análise Exploratória de Dados (EDA) sobre os microdados do ENEM 2023, publicados pelo INEP. O objetivo é investigar desigualdades educacionais no Brasil cruzando o desempenho dos candidatos com fatores socioeconômicos e demográficos: renda familiar, tipo de escola, sexo, cor/raça e localização geográfica.

O projeto foi desenvolvido como peça de portfólio em Data Science, demonstrando o ciclo completo de um projeto de dados: coleta, limpeza, exploração, visualização e síntese de insights.

2. Problema e Perguntas de Negócio

As seguintes perguntas nortearam toda a análise:

- Qual é o impacto da renda familiar no desempenho no ENEM?
- Candidatos de escolas privadas têm vantagem em todas as áreas do conhecimento?
- A vantagem da escola privada se mantém mesmo dentro da mesma faixa de renda?
- Como o desempenho varia entre os 27 estados e 5 regiões do Brasil?
- Existem diferenças de desempenho por sexo? Elas são uniformes entre as áreas?
- Candidatos de diferentes grupos de cor/raça apresentam desempenhos distintos?
- Quando múltiplos fatores desfavoráveis se somam, qual é o tamanho da desvantagem composta?

3. Dataset

Item	Detalhe
Fonte	INEP — Microdados do ENEM 2023
Registros totais	3.933.955 candidatos
Amostra coletada	500.000 registros (amostragem aleatória)
Amostra limpa analisada	370.141 candidatos (após remoção de ausentes)
Registros removidos	~130.000 (26%) — candidatos ausentes em pelo menos uma prova
Formato original	CSV com separador ; e encoding latin-1
Formato processado	Parquet (via PyArrow)

Variáveis utilizadas

Coluna original	Descrição
NU_NOTA_CN	Nota — Ciências da Natureza
NU_NOTA_CH	Nota — Ciências Humanas
NU_NOTA_LC	Nota — Linguagens e Códigos
NU_NOTA_MT	Nota — Matemática
NU_NOTA_REDACAO	Nota — Redação
Q006	Faixa de renda familiar (categorias A a P)
TP_ESCOLA	Tipo de escola (1=Não respondeu, 2=Pública, 3=Privada, 4=Exterior)
SG_UF_PROVA	Sigla do estado onde a prova foi realizada
TP_SEXO	Sexo do candidato (M/F)
TP_COR_RACA	Cor/raça autodeclarada (0–6)

4. Stack Tecnológica

Ferramenta	Versão	Uso
Python	3.11	Linguagem principal
Pandas	2.2.2	Manipulação e análise de dados
NumPy	1.26.4	Operações numéricas
Matplotlib	3.9.0	Visualizações estáticas
Seaborn	0.13.2	Gráficos estatísticos
Plotly	5.22.0	Mapa choropleth interativo
PyArrow	16.1.0	Leitura/escrita em Parquet
Requests	2.32.3	Download do GeoJSON do IBGE

Jupyter	1.0.0	Ambiente de desenvolvimento
---------	-------	-----------------------------

5. Estrutura do Projeto

enem-insights/

```

├── data/
│   ├── raw/                # Arquivo ZIP original (não
versionado)
│   └── processed/          # Parquet gerado após limpeza
├── notebooks/              # 5 notebooks em ordem de execução
├── src/utils.py            # Mapeamentos, estilos e funções
reutilizáveis
├── reports/figures/        # 21 gráficos PNG + 1 mapa HTML
interativo
├── .gitignore
├── requirements.txt
└── README.md

```

6. Metodologia — Notebooks

Notebook 01 — Carregamento e Limpeza

Objetivo: transformar o CSV bruto em um dataset limpo e eficiente para análise.

- Leitura do arquivo ZIP diretamente via `zipfile.ZipFile`, sem descompactar no disco
- Seleção das 10 colunas de interesse dentre as ~150 disponíveis nos microdados
- Filtragem: remoção de candidatos com nota NaN em qualquer prova (ausentes/faltosos)
- Aplicação de mapeamentos categóricos: renda (A–P → texto), escola (1–4 → texto), cor/raça (0–6 → texto)
- Conversão de colunas categóricas para `dtype category` do pandas (redução de memória de ~38MB para ~21MB)
- Criação da coluna derivada `NOTA_MEDIA` (média aritmética das 5 notas)
- Exportação para Parquet com PyArrow

Resultado: dataset limpo com 370.141 registros e 11 colunas, pronto para análise.

Notebook 02 — Análise Univariada

Objetivo: entender a distribuição individual de cada variável antes de cruzá-las.

Variável	Média	Mediana	Desvio Padrão
Nota Geral (média das 5 áreas)	541,6 pts	538,8 pts	—
Matemática	524,2 pts	510,1 pts	127,0 pts
Redação	647,5 pts	640,0 pts	—
Ciências Humanas	~550 pts	—	—
Linguagens e Códigos	~540 pts	—	—

Perfil demográfico da amostra:

Dimensão	Dado
Sexo	69,2% feminino (256.157) · 30,8% masculino (113.984)
Tipo de escola	54,3% não respondeu; entre quem respondeu: 87,3% pública · 12,7% privada
Cor/raça	Parda 44,4% · Branca 39,3% · Preta 13,2%
Renda	61,3% em faixas até R\$ 1.980; faixa mais comum: Até R\$ 1.320 (36,9%)
Amplitude de estados	67,1 pts entre MG (572,7 pts) e AM (505,6 pts)

Notebook 03 — Análise Bivariada

Objetivo: cruzar o desempenho com cada variável socioeconômica e identificar a magnitude das desigualdades.

#	Insight	Evidência
1	Escola privada supera pública em todas as áreas	+163 pts em Redação · +130 pts em Matemática · +101 pts na média
2	Renda e desempenho têm relação monotônica crescente	+172 pts entre a faixa Sem renda e Acima de R\$ 39.600
3	Desigualdade racial estrutural	Indígenas -82 pts vs brancos · Pretos -52 pts · Pardos -46 pts
4	Diferença por sexo é área-específica, não global	Homens +38 pts em Matemática · Mulheres +39 pts em Redação
5	Vantagem da escola privada independe da renda	Privada supera pública em todas as 16 faixas — gap mínimo de 45 pts

O insight 5 é o mais relevante: demonstra que o tipo de escola tem um efeito próprio, separado do poder aquisitivo da família.

Notebook 03b — Análise Geográfica

Objetivo: mapear o desempenho pelos 27 estados e 5 regiões, com recorte específico sobre o Nordeste e Pernambuco.

#	Insight	Evidência
1	Variação expressiva entre estados	67 pts entre MG (572,7) e AM (505,6)
2	Sul e Sudeste lideram com folga	Mediana ~557–561 pts vs Norte ~509 pts (+52 pts)
3	Matemática tem maior desigualdade regional	Amplitude de 87 pts: MG (565,7) vs AP (478,9)
4	DF se destaca no Centro-Oeste	558,3 pts — 16,7 pts acima da média nacional

Recorte — Pernambuco no Nordeste:

- PE é o 1º colocado no Nordeste com 539,8 pts
- PE ocupa o 10º lugar no ranking nacional dos 27 estados
- PE supera a média nordestina em todas as 5 áreas de conhecimento
- Maior diferença em Matemática: +17,2 pts acima da média regional

Notebook 04 — Insights Finais

Objetivo: consolidar todos os achados em uma narrativa única com visualizações síntese.

Fator	Gap (pts)
Renda (sem renda → acima R\$ 39k)	172
Tipo de escola (privada → pública)	101
Raça (branca → indígena)	82
Raça (branca → preta)	52
Região (Sul/Sudeste → Norte)	52
Raça (branca → parda)	46
Gênero — Redação (feminino → masculino)	39
Gênero — Matemática (masculino → feminino)	38

Conclusão central: as desigualdades se acumulam. O gap entre o perfil mais privilegiado (escola privada + renda alta + branco) e o mais desfavorecido (escola pública + renda baixa + indígena) supera 200 pontos — mais de 1,5 desvio padrão da distribuição geral.

7. Módulo Utilitário — src/utils.py

Arquivo Python com funções e constantes reutilizadas em todos os notebooks, evitando duplicação de código.

Constantes

- MAPA_RENDA — tradução das categorias A–P para texto descritivo
- MAPA_ESCOLA — mapeamento dos códigos 1–4 para tipo de escola
- MAPA_COR_RACA — mapeamento dos códigos 0–6 para categorias de cor/raça
- NOTAS_COLS / NOTAS_LABELS — lista e dicionário das 5 colunas de nota
- PALETTE, FIGSIZE_DEFAULT — configurações visuais padrão

Funções

Função	Descrição
configurar_estilo()	Aplica tema whitegrid e remove bordas superior/direita dos eixos
salvar_figura(fig, nome, pasta)	Exporta figura Matplotlib em PNG para reports/figures/
nota_media(df)	Calcula média das 5 notas por candidato (ignora NaN)
formatar_eixo_mil(ax, eixo)	Formata eixo com separador de milhar no padrão PT-BR

8. Visualizações Geradas

O projeto produziu 22 arquivos de saída em reports/figures/:

Notebook 02 — Análise Univariada

- 02_histogramas_notas.png — Distribuição por área (histograma + KDE)
- 02_kde_comparativo.png — KDE das 5 áreas sobrepostas
- 02_boxplot_notas.png — Boxplot comparativo entre áreas
- 02_distribuicao_escola.png — Proporção por tipo de escola
- 02_distribuicao_sexo.png — Proporção por sexo
- 02_distribuicao_raca.png — Proporção por cor/raça
- 02_distribuicao_renda.png — Distribuição por faixa de renda
- 02_ranking_estados.png — Ranking dos 27 estados por nota média

Notebook 03 — Análise Bivariada

- 03_nota_por_escola.png — Nota média por tipo de escola
- 03_nota_por_renda.png — Nota média por faixa de renda
- 03_heatmap_renda_area.png — Heatmap renda × área de conhecimento
- 03_nota_renda_por_escola.png — Nota por renda segmentada por escola
- 03_nota_por_raca.png — Nota por cor/raça
- 03_notas_por_sexo.png — Nota por área × sexo

Notebook 03b — Análise Geográfica

- 03b_ranking_estados.png — Ranking colorido por região
- 03b_nota_por_regiao.png — Boxplot regional
- 03b_heatmap_uf_area.png — Heatmap estado × área
- 03b_recorte_nordeste_pe.png — Comparativo PE vs demais estados do Nordeste
- 03b_mapa_interativo.html — Mapa choropleth interativo (Plotly)

Notebook 04 — Insights Finais

- 04_mapa_desigualdades.png — Amplitude dos gaps por fator
- 04_desvantagem_composta.png — Comparação dos perfis extremos

9. Decisões Técnicas Relevantes

Amostragem

Com 3,9 milhões de registros, o dataset completo seria pesado para EDA exploratória. Uma amostra aleatória de 500k registros (12,7% do total) foi suficiente para obter estimativas estáveis das métricas investigadas.

Formato Parquet

Após a limpeza no notebook 01, o dataset é salvo em Parquet. Isso reduz o tempo de carregamento nos notebooks seguintes e mantém os tipos de coluna (inclusive category) sem necessidade de reprocessamento.

Mapa interativo sem tiles externos

`px.choropleth_mapbox` com `mapbox_style='white-bg'` funciona sem requisitar CDN externo, garantindo renderização consistente em qualquer ambiente. Alternativas como `carto-positron` falhavam silenciosamente em redes restritas.

Média nacional ponderada vs. média de médias estaduais

Ao calcular a média nacional, foi usada `df['NOTA_MEDIA'].mean()` (541,6 pts) e não `nota_uf['nota_media'].mean()` (536,6 pts). A segunda é uma média não ponderada das médias estaduais, enviesada por estados com poucos candidatos, e não representa a média real do país.

10. Histórico de Commits

Hash	Mensagem
430a5c4	Initial commit
7dcb9c3	feat: estrutura do projeto e notebook de carregamento/limpeza
4af7977	feat: notebooks 01 e 02 com dados ENEM 2023 + README profissional
d38bb5c	feat: notebook 03 de análise bivariada com insights reais
5f672bf	feat: notebook 03b de análise geográfica com mapa choropleth interativo
628a841	chore: atualiza metadados de execução do notebook 03
15dbf8d	fix: corrige inconsistências encontradas na revisão do projeto
c557b18	docs: preenche observações com valores reais e atualiza README
dc6ed6d	feat: notebook 04 de insights finais com gráficos síntese
9aad69d	fix: corrige ano do ENEM de 2024 para 2023 nos títulos do notebook 02
3a2457f	docs: adiciona docstrings Google Style em todas as funções de utils.py
708bf87	docs: adiciona LinkedIn na seção Autor do README
102ebca	fix: adiciona regras globais para *.zip e *.csv no .gitignore
96d96fd	feat: adiciona seção de recorte regional Nordeste/PE no notebook 03b
7578242	fix: corrige media_nacional na seção PE/Nordeste e atualiza README
6c06e1f	chore: atualiza outputs de execução (EOL e mapa HTML regenerado)

11. Como Reproduzir

1. Clone o repositório:

```
git clone https://github.com/Rodrigotorres1/ENEM-Insights.git
```

2. Instale as dependências:

```
pip install -r requirements.txt
```

3. Baixe os microdados do ENEM 2023 no portal do INEP e coloque o ZIP em data/raw/

4. Execute os notebooks em ordem:

```
jupyter notebook notebooks/
```

Requisito mínimo: Python 3.11+

12. Limitações e Possíveis Extensões

Limitações

- A análise é descritiva (EDA), não causal. Correlações identificadas não estabelecem causalidade.
- A amostra de 500k exclui 87% do dataset; padrões de grupos menores podem ser subestimados.
- A variável TP_ESCOLA tem 54,3% de Não respondeu, limitando a análise de tipo de escola.
- Sem dados de anos anteriores, não é possível identificar tendências temporais.

Possíveis Extensões

- Análise temporal: comparar os dados de 2019 a 2023 para observar impacto da pandemia
- Modelagem preditiva: regressão ou gradient boosting para prever nota a partir das variáveis socioeconômicas
- Análise municipal: os microdados incluem município de residência, permitindo granularidade além do estado
- Dashboard interativo: transformar os insights em um painel Streamlit ou Dash